

Static Tucker: forward/backward и Muon

H100 80GB HBM3, BF16, Llama 257M, seq 1024

1 Протокол

Llama 257M, H100 80GB HBM3, BF16, sequence length 1024. Capacity sweep обрабатывает 16,384 токена за optimizer step: microbatch 1/2/4/8/16 и accumulation 16/8/4/2/1. Для каждой точки выполнено 3 warmup и 12 измеряемых шагов.

Основная метрика — сумма CUDA Event-времен forward и backward. Она не включает gradient clipping, optimizer, QR-retraction и vector transport. Dense Muon использует 5 Newton-Schulz steps; Tensorion — 6. У Tucker core и четыре factor direction запускаются в пяти CUDA streams.

2 Forward + backward, мс

Метод	bs 1	bs 2	bs 4	bs 8	bs 16
Dense AdamW	360.7	178.2	118.2	113.3	106.8
Dense Muon	368.5	177.8	118.6	113.4	107.8
Static Tucker	1318.4	651.5	329.9	209.8	198.3

3 Forward + backward throughput, токенов/с

Метод	bs 1	bs 2	bs 4	bs 8	bs 16
Dense AdamW	45,419	91,967	138,652	144,600	153,346
Dense Muon	44,466	92,160	138,114	144,516	152,005
Static Tucker	12,427	25,147	49,668	78,085	82,629

Dense AdamW и Dense Muon имеют практически одинаковый forward/backward. Tucker медленнее Muon в 3.58/3.67/2.78/1.85/1.84 раза. Следовательно, разница находится в factorized contraction и её backward, а не в выборе optimizer backend.

4 Optimizer section, мс

Tucker-метрика включает Tensorion/Riemannian-Muon, coupled LR scaling, QR-retraction и vector transport.

Метод	bs 1	bs 2	bs 4	bs 8	bs 16
Dense AdamW	1.8	1.8	1.8	1.8	1.8
Dense Muon	42.8	40.6	33.5	34.3	34.7
Static Tucker	586.7	582.3	585.3	574.8	574.7
Tucker sequential (old)	444.4	424.4	398.1	446.8	439.4

Пять CUDA streams замедлили optimizer на 29–47 %; основная стоимость не сводится к пяти последовательным Muon.

5 Полный шаг, мс

Метод	bs 1	bs 2	bs 4	bs 8	bs 16
Dense AdamW	364.2	181.5	120.9	116.0	109.5
Dense Muon	413.0	219.8	153.0	148.4	143.4
Static Tucker	1909.1	1237.4	919.0	786.6	775.3

6 Peak CUDA allocated memory, ГБ

Метод	bs 1	bs 2	bs 4	bs 8	bs 16
Dense AdamW	3.27	4.41	6.61	11.02	19.28
Dense Muon	2.96	4.10	6.28	10.69	18.98
Static Tucker	4.23	6.49	10.73	19.42	36.26

7 Production: microbatch 32 × accumulation 4

Метод	F+B, мс	Opt, мс	Шаг, мс	Peak, ГБ
Dense AdamW	821.571	1.750	824.186	37.441
Dense Muon	827.650	35.009	863.574	37.136
Static Tucker	1499.104	571.316	2073.215	71.539

Production Tucker forward+backward в 1.81 раза медленнее Dense Muon. Параллельный optimizer в 1.21 раза медленнее старого результата 473.725 ms.

8 Контроль корректности

Все 84 Tucker-слоя работали в режиме contract. Self-test заменял materialize_weight на исключение. Commit 69e569c; capacity job lm-mpi-job-0583f75d-0fa8-4f7b-8e5e-18d8fae2f90a; production job lm-mpi-job-f405573b-c021-46cc-bad7-5103d709b023.