

Static Tucker: время и память

H100 80GB HBM3, BF16, Llama 257M, seq 1024

1 Протокол и контроль корректности

Сравниваются плотный Llama с 257,188,864 параметрами и static Tucker с 257,676,352 параметрами. В capacity sweep на каждом шаге обрабатывается 16,384 токена: microbatch меняется от 1 до 16, а accumulation — от 16 до 1. Для каждой точки выполнено 3 warmup и 12 измеряемых шагов.

Во всех 84 Tucker-слоях зафиксирован режим contract. Отдельный self-test заменяет materialize_weight на исключение и успешно выполняет forward, backward, Tensorion step, QR-retraction и vector transport.

2 Полный шаг обучения, мс

Метод	bs 1	bs 2	bs 4	bs 8	bs 16
Dense AdamW	264.1	153.1	120.6	115.3	110.0
Static Tucker	1675.1	968.2	645.4	659.1	638.8

3 Пропускная способность, токенов/с

Метод	bs 1	bs 2	bs 4	bs 8	bs 16
Dense AdamW	62,038	106,990	135,876	142,144	149,006
Static Tucker	9,781	16,923	25,396	24,858	25,651

4 Пиковая CUDA allocated memory, ГБ

Метод	bs 1	bs 2	bs 4	bs 8	bs 16
Dense AdamW	3.27	4.41	6.61	11.02	19.28
Static Tucker	4.06	6.33	10.56	19.26	36.09

5 Время оптимизатора, мс

Для Tucker сюда входят Tensorion/Riemannian-Muon, QR-retraction и перенос состояния оптимизатора.

Метод	bs 1	bs 2	bs 4	bs 8	bs 16
Dense AdamW	1.8	1.8	1.8	1.8	1.8
Static Tucker	444.4	424.4	398.1	446.8	439.4

6 Параметры и постоянная память, ГБ

Метод	Параметры	Модель	Optimizer state
Dense AdamW	257.189M	0.514	1.029
Static Tucker	257.676M	0.515	0.723

Static Tucker уменьшает optimizer state на 30 %, но модель практически iso-param с плотной и требует больше activation/workspace memory.

7 Production point: microbatch 32 × accumulation 4

На один optimizer step приходится 131,072 токена.

Метод	Шаг, мс	Токенов/с	Пик, ГБ	Optimizer, мс
Dense AdamW	823.389	159,186	37.441	1.753
Static Tucker	1973.803	66,406	71.364	473.725

Production-конфигурация Tucker помещается на H100 80GB с запасом около 8.6 ГБ, но шаг в 2.40 раза медленнее dense AdamW. В capacity sweep при microbatch 16 замедление составляет 5.81 раза, а peak memory — 1.87 от dense.

8 Воспроизводимость

GPU: NVIDIA H100 80GB HBM3; BF16 storage; sequence length 1024. Benchmark commit: 3cdf678.

Full sweep: lm-mpi-job-2fe89f50-a619-450c-a2f2-b09f7ca2c6a2.

Production point: lm-mpi-job-a8578193-cca9-46ea-a4c3-464fdb1d5a24.